

UNIVERSIDADE D
COIMBRA

Universidade de Coimbra
Faculdade de Ciências e Tecnologias
Departamento de Engenharia Informática

Modelo Bayesiano para Classificação

Fusão de Informação em Análise de Dados

Autores:
Afonso Rodrigues – 2020242400
Emanuel Pacheco – 2024138898

Professor:
Alberto Cardoso
Jorge Henriques

20 de junho de 2025

Conteúdo

1 Introdução **1**

2 Processamento de Dados **1**
2.1 Discretização de *Features* 1
2.2 Adição de novas *features* 2

3 Implementação do Modelo Bayesiano **2**
3.1 Probabilidade a Priori 2
3.2 Probabilidades Condicionais 2
3.3 Lógica da Previção 2
3.4 Implementação em Python 3

4 Avaliação do Modelo **3**

5 Questões **4**
5.1 O desempenho do classificador é aceitável? 4
5.2 Variáveis Discretas vs. Contínuas 4
5.3 As probabilidades condicionais assumem distribuição normal? 4
5.4 Outras distribuições ou Misturas Gaussianas? 5

6 Conclusão **5**

Aviso: O uso de ferramentas de IA e de LLM foi utilizado para correção de gramática e assistência geral no desenvolvimento do código.

1 Introdução

Este trabalho apresenta a implementação de um modelo Bayesiano para classificar decisões com base em um conjunto de dados real. Utilizamos técnicas de pré-processamento, como a discretização de variáveis, para simplificar o modelo e facilitar a interpretação dos resultados. O objetivo principal foi demonstrar a eficácia de métodos probabilísticos simples na análise e previsão de decisões.

2 Processamento de Dados

Para preparar o *dataset* para classificação Bayesiana, procedemos a vários passos de pré-processamento, com o objetivo de simplificar o modelo e melhorar sua interpretabilidade.

Além das técnicas aplicadas, também efetuamos trabalho básico de limpeza (verificação de valores nulos, inválidos, etc.).

2.1 Discretização de *Features*

Para aplicarmos um modelo Bayesiano baseado em frequência, variáveis contínuas foram discretizadas em categorias semanticamente significativas, e não com base em igual frequência por categoria.

As variáveis contínuas presentes no nosso dataset são: Idade (*Age*) e Salário Mensal (*MonthlySalary*). Para a variável idade, discretizamos da seguinte forma:

Label	**Idade**
Young Adult	18–29 (0)
Adult	30–39 (1)
Mature Adult	40–49 (2)
Middle Aged	50–59 (3)
Senior	60+ (4)

Tabela 1. Intervalo de Idades

Para a variável Salário Mensal, a discretização foi realizada da seguinte maneira:

Salário	**Label**
< 1499	Low Income (0)
1500–2999	Mid Income (1)
3000+	High Income (2)

Tabela 2. Intervalo de Salários

A justificação para esta definição de intervalos não se baseou em um método específico, mas sim em lógica própria, parcialmente inspirada no sistema de recomendação para compra de seguros de vida.

2.2 Adição de novas *features*

Como o *dataset* original não continha a recomendação para compra de seguro de vida, decidimos adicionar essa coluna com base nas regras apresentadas. Os intervalos definidos na secção anterior foram, de certa forma, inspirados nesses valores, com algumas adaptações.

3 Implementação do Modelo Bayesiano

Um modelo bayesiano foi implementado desde o início sem a utilização de bibliotecas externas, conforme os requisitos do projeto. Apresentamos agora os passos principais para a realização deste modelo.

3.1 Probabilidade a Priori

As probabilidades a priori para cada classe (decisão de comprar ou não) foram calculadas com base na frequência de cada classe no *dataset*:

$$P(T = 1) = \frac{\text{Número de indivíduos que compraram}}{\text{Número total de indivíduos}} \tag{1}$$

3.2 Probabilidades Condicionais

Para cada *feature* X_i e cada classe $T \in \{0, 1\}$, as probabilidades condicionais foram estimadas:

$$P(X_i = x|T = t) = \frac{\text{Número de } \textit{samples} \text{ onde } X_i = x \text{ e } T = t}{\text{Número de } \textit{samples} \text{ onde } T = t} \tag{2}$$

Todas as variáveis foram processadas de forma independente (conforme a suposição de independência condicional do Naive Bayes). Aplicamos *Laplace Smoothing* para evitar casos de probabilidade zero quando categorias não estão representadas no conjunto de treino.

3.3 Lógica da Previção

Para uma nova *sample* $\mathbf{x} = [x_1, x_2, \ldots, x_8]$, a probabilidade posterior foi calculada usando o teorema de Bayes:

$$P(T = t \mid \mathbf{x}) \propto P(T = t) \cdot \prod_{i=1}^{n} P(X_i = x_i \mid T = t) \tag{3}$$

A classe prevista é determinada por:

$$\text{Predição} = \arg\max_{t \in \{0,1\}} P(T = t \mid \mathbf{x}) \tag{4}$$

3.4 Implementação em Python

Foi criada uma classe para armazenar as probabilidades condicionais calculadas com base na divisão do *dataset*, contendo as seguintes funções:

- `def priori_cal(y)`: Recebe os rótulos (y) e retorna a probabilidade de cada classe, bem como a contagem total de cada classe;
- `def calculate_condition(X, y, categories, prior_counts, name)`: Calcula as probabilidades condicionais com base na *feature* (X), nos rótulos (y), nas categorias da *feature* (categories) e no tamanho de cada classe (prior_counts). O último argumento serve para nomear corretamente a entrada no dicionário;
- `def calculate_likelihood(X)`: Calcula a *likelihood* para uma dada amostra X;
- `def train(X,y)`: Função principal que invoca `priori_cal(...)` e `calculate_condition(...)` para cada *feature*, armazenando os valores num dicionário;
- `def predict(X)`: Recebe uma amostra X, calcula a *likelihood* e retorna 1 se o resultado for superior a 50%, caso contrário retorna 0;
- `def print_probabilities()`: Exibe detalhadamente as probabilidades condicionais de cada categoria de cada *feature*.

4 Avaliação do Modelo

Como métrica de avaliação, utilizamos a *accuracy*, uma vez que o *dataset* apresenta um desbalanceamento moderado na variável target *Decision*, com aproximadamente 68% de decisões negativas contra 32% de decisões positivas.

Ao treinar e testar nosso modelo com o *dataset* completo, obtivemos uma *accuracy* de 80.33%, resultado que consideramos satisfatório. Para avaliar a robustez do modelo, testamos diferentes proporções de divisão treino-teste, obtendo os seguintes resultados:

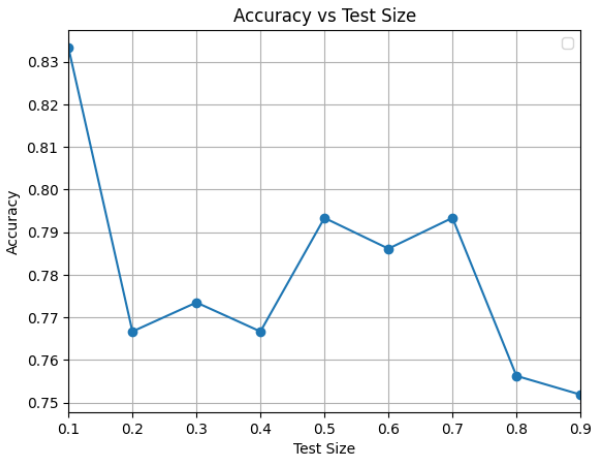


Figura 1. Impacto da proporção treino-teste na acurácia do modelo

Observamos que, como esperado, o desempenho geral do modelo melhora com maiores volumes de dados de treino. É notável que mesmo com apenas 60 amostras (10% do *dataset*), o modelo alcança uma *accuracy* de 75%, demonstrando sua eficácia mesmo em condições de treino limitado.

5 Questões

5.1 O desempenho do classificador é aceitável?

Como referido no capítulo 4, sim.

Devem todas as variáveis ser usadas?

Como o nosso melhor desempenho foi com um *split* 90/10, os resultados apresentados refletem essa configuração.

Hipoteticamente, nem todas as variáveis seriam necessárias para construir o modelo. Variáveis como **Gender** e **Suggestion** apresentam distribuições condicionais semelhantes entre as classes e, nesse contexto, poderiam ser excluídas sem alterar a estrutura lógica do modelo.

Por outro lado, variáveis como **Age**, **NumberOfChildren**, **ChronicDisease** e **MonthlySalary** apresentam distribuições distintas entre as classes, sendo relevantes para a diferenciação entre as decisões.

Assim, num cenário puramente analítico, seria possível construir o modelo utilizando apenas um subconjunto das variáveis disponíveis.

5.2 Variáveis Discretas vs. Contínuas

Como referido no Capítulo 2, optámos por discretizar todas as variáveis, com o objetivo de simplificar o modelo e aumentar a sua interpretabilidade.

A utilização de variáveis discretas permite calcular probabilidades condicionais com base apenas nas frequências observadas em cada classe, sem necessidade de assumir distribuições específicas. Por outro lado, o tratamento de variáveis contínuas exigiria a modelação de distribuições (por exemplo, assumindo normalidade), o que introduz complexidade adicional.

5.3 As probabilidades condicionais assumem distribuição normal?

Não. Neste trabalho, as probabilidades condicionais foram estimadas com base em frequências absolutas obtidas a partir de variáveis discretizadas.

Optámos por não assumir qualquer forma paramétrica (como a distribuição normal) para os dados, uma vez que a discretização torna essa suposição desnecessária. Além disso, a estrutura do modelo Bayesiano utilizado baseia-se na contagem de ocorrências para cada combinação de variável e classe, não exigindo qualquer modelação estatística adicional.

5.4 Outras distribuições ou Misturas Gaussianas?

Neste trabalho, utilizámos apenas probabilidades condicionais baseadas em contagens discretas, sem recorrer a qualquer tipo de distribuição contínua.

No entanto, como trabalho futuro, seria interessante explorar a utilização de modelos mais avançados, como as *Gaussian Mixture Models* (GMMs), para representar variáveis contínuas de forma mais flexível. Estes modelos permitiriam capturar distribuições mais complexas e possivelmente melhorar a performance do classificador, especialmente em casos onde a discretização possa perder informação relevante.

6 Conclusão

O modelo Bayesiano desenvolvido permitiu classificar com sucesso a decisão de adquirir seguro de vida, alcançando uma *accuracy* aceitável. A discretização das variáveis revelou-se eficaz, simplificando o processo e mantendo bons resultados. O trabalho demonstrou a aplicabilidade de métodos probabilísticos simples na tomada de decisão com base em dados reais.